

Отчёт по проекту

Студент: Коновченко Петр Михайлович

Группа: БИВ236

1. Введение и постановка задачи

Цель проекта — построить модель, которая по характеристикам финансовой транзакции предсказывает значение Money Laundering Risk Score: уровень риска того, что операция связана с отмыванием денежных средств. Практическая ценность — автоматизация первичной оценки, снижение нагрузки на специалистов.

Формулировка задачи. Целевая переменная принимает дискретные значения от 1 до 10, поэтому задача — **многоклассовая классификация** (10 классов).

Обоснование метрики качества. В качестве основной метрики выбран **weighted F1-score**. Accuracy будем использовать для наглядности. Weighted F1-score усредняет precision и recall по всем классам с учётом их частоты, поэтому лучше отражает качество классификатора в многоклассовой задаче.

2. Поиск и описание данных

Источник. Использовался датасет **Global Black Money Transactions Dataset** с платформы Kaggle. Выбор обусловлен соответствием требованиям + датасет описывает финансовые транзакции - это интересно.

Объём и состав. Датасет содержит **10 000 строк** и **14 столбцов**, из которых один — целевая переменная.

Признак	Тип	Описание
Transaction ID	категориальный	Уникальный идентификатор транзакции
Country	категориальный	Страна отправителя
Amount (USD)	числовой	Сумма операции в долларах США
Transaction Type	категориальный	Тип транзакции (Cash, Crypto, Transfer и др.)
Date of Transaction	дата	Дата и время совершения операции
Person Involved	категориальный	Имя участника транзакции
Industry	категориальный	Отрасль деятельности участника
Destination Country	категориальный	Страна получателя
Reported by Authority	булев	Признак сообщения о транзакции в органы
Source of Money	категориальный	Источник денежных средств (Legal / Illegal)

Shell Companies Involved	числовой	Число вовлечённых подставных компаний
Financial Institution	категориальный	Финансовое учреждение (499 уникальных значений)
Tax Haven Country	категориальный	Страна налоговой гавани
Money Laundering Risk Score	числовой (целевая)	Уровень риска отмывания денег, 1–10

3. Обработка и подготовка данных

Очистка данных

Датасет является синтетическим, поэтому пропущенных значений и полных дубликатов строк выявлено не было. Единственный непрерывный признак — сумма транзакции — проверен на выбросы: аномальных значений не обнаружено. Числовые признаки приведены к числовому типу, категориальные — к типу `category`.

Feature Engineering

Итоговое число признаков в модели: **17** (после удаления нескольких колонок и добавления новых).

Новый признак	Из чего	Смысл
transaction_year, transaction_month, transaction_dayofweek, transaction_hour	Date of Transaction	Временные паттерны (сезонность, час суток)
is_illegal	Source of Money	Бинарный флаг: 1 = незаконный источник
is_reported	Reported by Authority	Бинарный флаг: 1 = сообщено в органы
has_tax_haven	Tax Haven Country	Бинарный флаг: 1 = есть офшорная юрисдикция
log_amount	Amount (USD)	для сглаживания распределения и уменьшения модуля значений
Financial Institution_grouped	Financial Institution	Топ-20 банков по частоте; остальные → OTHER

Удалены: Transaction ID, Person Involved (идентификаторы без предсказательной ценности), Date of Transaction (заменена временными признаками), Source of Money и Reported by Authority (заменены бинарными флагами).

Анализ целевой переменной

Распределение классов риска практически равномерное — каждый из 10 уровней

встречается приблизительно с одинаковой частотой (~1 000 объектов), что исключает проблему дисбаланса классов.

[image]

Корреляция числовых признаков с таргетом крайне мала: максимальное значение $|r|$ не превышает **0.02**. Это ключевой вывод: числовые признаки не несут линейной информации о классе риска.

[image]

Ящичные диаграммы по категориальным признакам также не выявляют значимой дифференциации уровней риска.

[image]

[image]

[image]

[image]

[image]

Сплит данных

Разбивка выполнена стратифицированным образом по таргету в соотношении **70 / 15 / 15**:

Выборка Объектов

train	7 000
val	1 500
test	1 500

Data leakage исключён: все трансформации (LabelEncoder, ONE) обучались только на train и применялись к val/test без переобучения.

4. Baseline-модель

Гипотеза. Простая линейная модель задаёт нижнюю планку качества.

Модель. `LogisticRegression (solver = lbfgs, max_iter = 1000)` с LabelEncoding категориальных признаков, без ONE.

Результаты.

Выборка Accuracy Weighted F1

val	0.1027	0.0742
test	0.1133	0.0818

Вывод. Качество вплотную к случайному угадыванию ($1/10 = 0.10$). Линейная модель

не способна выделить паттерны в данных — ожидаемо, учитывая близкие к нулю корреляции всех признаков с таргетом.

5. Эксперименты

Все эксперименты проводились на одинаковой ONE-матрице признаков (67 колонок после one-hot encoding категориальных переменных). Выбор лучших гиперпараметров — по weighted F1 на validation. Seed фиксирован: `RANDOM_STATE = 42`.

Эксперимент 1: LogisticRegression + ONE

Гипотеза. One-hot encoding категориальных признаков даст линейной модели больше информации и улучшит качество по сравнению с baseline на LabelEncoding.

Как проверялось. `LogisticRegression` (`lbfgs`, `max_iter=1000`) обучена на ONE-матрице (67 признаков). Результат сравнён с baseline.

Результат.

Выборка Accuracy Weighted F1

val	0.1073	0.0704
test	0.1087	0.0721

Вывод. ONE не улучшил качество — weighted F1 даже незначительно снизился по сравнению с baseline. Гипотеза не подтвердилась: разбиение категорий на бинарные колонки не помогает линейной границе разделить 10 классов риска.

Эксперимент 2: KNN + ONE (grid search)

Гипотеза. Метод ближайших соседей может уловить локальные структуры в пространстве признаков, которые линейная модель игнорирует. Подбор `k`, метрики и весовой схемы улучшит качество.

Как проверялось. Grid search по `k ∈ {1..9}`, `weights ∈ {uniform, distance}`, `p ∈ {1, 2}` через `Pipeline(StandardScaler → KNeighborsClassifier)`. Лучший набор выбран по val F1.

Результат.

Выборка	Accuracy	Weighted F1	Лучшие параметры
val	0.1160	0.1157	<code>k = 4</code> , <code>weights = distance</code> , <code>p = 2</code>
test	0.1060	0.1057	—

Вывод. KNN превзошёл логистическую регрессию, однако расхождение val/test (~0.01 по F1) указывает на лёгкое переобучение к валидационной выборке. Прирост незначительный — модель по-прежнему работает около случайного уровня.

Эксперимент 3: RandomForest + OHE (grid search)

Гипотеза. Ансамбль решающих деревьев способен улавливать нелинейные взаимодействия признаков и должен показать лучшее качество, чем KNN и логистическая регрессия.

Как проверялось. Grid search по $n_estimators \in \{50, 100, 200\}$, $max_depth \in \{None, 10, 20\}$, $min_samples_split \in \{2, 5\}$, $min_samples_leaf \in \{1, 2\}$, $max_features \in \{sqrt, log2\}$. Всего 72 конфигурации.

Результат.

Выборка	Accuracy	Weighted F1	Лучшие параметры
val	0.1220	0.1217	$n = 200$, $depth = None$, $mss = 2$, $mssl = 1$, $mf = sqrt$
test	0.1067	0.1063	—

Вывод. RandomForest показал наилучший val F1 среди всех моделей. Тем не менее расхождение val/test (~ 0.015) сохраняется, что говорит о переобучении к validation. Абсолютные значения по-прежнему близки к случайному уровню.

Эксперимент 4: GradientBoosting + OHE (grid search)

Гипотеза. Градиентный бустинг с настроенными $learning_rate$ и глубиной деревьев должен превзойти RandomForest за счёт последовательной коррекции ошибок.

Как проверялось. Grid search по $n_estimators \in \{50, 100, 200\}$, $learning_rate \in \{0.01, 0.05, 0.1, 0.2\}$, $max_depth \in \{2, 3, 5\}$. Всего 36 конфигураций.

Результат.

Выборка	Accuracy	Weighted F1	Лучшие параметры
val	0.1107	0.1083	$n = 50$, $lr = 0.10$, $depth = 5$
test	0.1093	0.1072	—

Вывод. GradientBoosting не превзошёл RandomForest на validation, хотя test-качество у него стабильнее (меньше расхождение val/test). Гипотеза не подтвердилась.

Сводная таблица экспериментов

Модель	Val Acc	Val F1	Test Acc	Test F1
Baseline (LogReg, LabelEnc)	0.1027	0.0742	0.1133	0.0818
LogisticRegression + OHE	0.1073	0.0704	0.1087	0.0721
KNN + OHE (best grid)	0.1160	0.1157	0.1060	0.1057
GradientBoosting + OHE (best grid)	0.1107	0.1083	0.1093	0.1072
RandomForest + OHE (best grid)	0.1220	0.1217	0.1067	0.1063

Общий вывод. Все четыре модели работают вблизи случайного угадывания. Это закономерное следствие результата EDA: ни числовые признаки ($|r| < 0.02$), ни

категориальные не коррелируют с таргетом в синтетическом датасете, где Money Laundering Risk Score, по всей видимости, был сгенерирован независимо от остальных признаков.

6. Финальная модель и интерпретируемость

Выбор финальной модели. Выбран `RandomForestClassifier` — единственная модель, достигшая $\text{val F1} = 0.1217$, наилучшего среди всех экспериментов. Финальная версия переобучена на объединённой выборке `train + val` (8 500 объектов) и оценена только на `test`.

Гиперпараметры:

- `n_estimators = 200`
- `max_depth = None`
- `min_samples_split = 2`
- `min_samples_leaf = 1`
- `max_features = "sqrt"`
- `random_state = 42`

Финальные метрики на test:

Accuracy Weighted F1

0.1007 0.0994

Интерпретируемость. При $\text{F1} \approx 0.10$ `feature importance` случайного леса не несёт практического смысла: модель распределяет важность почти равномерно среди всех признаков, что характерно для случая, когда ни один из них не является информативным. Ключевой вывод подтверждён на всех уровнях исследования:

- числовые корреляции с таргетом близки к нулю ($\max |r| = 0.019$);
- `box-plot` по всем категориальным признакам не показывает дифференциации уровней риска;
- ни одна из четырёх моделей не смогла существенно превзойти случайное угадывание.

Это указывает на то, что Money Laundering Risk Score в данном синтетическом датасете был сгенерирован независимо от остальных признаков — связи между фичами и таргетом фактически нет.

7. Заключение и выводы

Итоги. В ходе проекта была поставлена задача многоклассовой классификации транзакций по уровню риска отмыwania денег (10 классов). Проведён полный цикл ML-исследования: анализ данных, `feature engineering`, обучение `baseline` и четырёх экспериментальных моделей с перебором гиперпараметров. Лучший результат — $\text{weighted F1} = 0.0994$ на тесте (`RandomForest`, обученный на `train + val`) — не превышает уровень случайного угадывания (0.10).

Почему модели не работают. EDA однозначно показал отсутствие статистической зависимости между признаками и таргетом в данном датасете: корреляции числовых признаков с Money Laundering Risk Score не превышают $|r| = 0.02$, а распределения риска по всем категориальным переменным практически идентичны. Это характерно для синтетических датасетов, где целевая переменная генерируется независимо. Проблема не в моделях — они технически реализованы корректно, — а в фундаментальном отсутствии сигнала в данных.

Ограничения.

- Датасет синтетический: статистическая независимость таргета от признаков делает задачу неразрешимой на данных такого рода.

Возможные улучшения.

- Заменить датасет на реальные транзакционные данные с подтверждёнными метками.
- Добавить агрегатные признаки по участнику / учреждению / стране (частота транзакций, средний объём, доля подозрительных операций).